

Hochschule Bremen

Fakultät Elektrotechnik und Informatik

Abschlussarbeit

Vergleich von Machine-Learning Modellen für die Generierung von Schiffsbewegungen

von Gunnar Martens

Matrikelnummer 5133103

Studiengang: ATMEI
Semester: Sommersemester 2024
Abgabedatum: 11. Mai 2026
Erstprüfer: Prof. Dr.-Ing. Patrick Draheim
Zweitprüfer: M.Sc. Jannes Adam

Eigenständigkeitserklärung

Hiermit versichere ich, dass ich die vorliegende Arbeit selbstständig verfasst und keine anderen als die angegebenen Quellen und Hilfsmittel benutzt habe. Die Stellen der Arbeit, die anderen Werken dem Wortlaut oder dem Sinn nach entnommen wurden, sind durch Angaben der Herkunft kenntlich gemacht.

Diese Erklärung erstreckt sich auch auf in der Arbeit enthaltene Grafiken, Skizzen, bildliche Darstellungen sowie auf Quellen aus dem Internet. Die Arbeit habe ich in gleicher oder ähnlicher Form auch auszugsweise noch nicht als Bestandteil einer Prüfungs- oder Studienleistung vorgelegt.

Ich versichere, dass die eingereichte elektronische Version der Arbeit vollständig mit der Druckversion übereinstimmt.

Bremen, der 11. Mai 2026

Gunnar Martens (5133103)

Inhaltsverzeichnis

1	Einleitung	1
1.1	Motivation	1
1.2	Aufgabenstellung	1
1.3	Gliederung der Arbeit	3
2	Theorie	4
2.1	Verwandte Arbeiten	4
2.2	Berechnung der Wellenparameter	4
2.3	Entscheidungsbäume	6
2.4	Metriken	7
3	Methodik	9
3.1	Datenbeschreibung	9
3.1.1	Herkunft	9
3.1.2	Struktur	10
3.1.3	Vorverarbeitung	12
3.2	Modelltraining	17
3.2.1	Herangehensweise	17
3.2.2	Allgemeiner Modellvergleich	18
3.2.3	Detaillierter Modellvergleich	22
4	Ergebnisse	23
4.1	Vorverarbeitung	23
4.2	Modelltraining	23
5	Zusammenfassung und Ausblick	25
5.1	Zusammenfassung	25
5.2	Ausblick	25
	Literaturverzeichnis	27
	Abbildungsverzeichnis	28
	Tabellenverzeichnis	29

1 Einleitung

1.1 Motivation

Durch den intensiven Ausbau von Offshore-Windparks vor der deutschen Nordseeküste erhöht sich die Zahl der Windkraftanlagen stetig. Für die Wartung und Instandhaltung der Anlagen des Windparks “Nordsee One” sollen Menschen in Zukunft von Drohnen unterstützt werden. Dabei sollen Außenteile der Windkraftanlagen inspiziert und Mängel erkannt werden. Der betreffende Windpark liegt ca. 35km nördlich der Insel Juist. Die Techniker, deren Equipment und die dafür eingesetzten Drohnen werden auf einem kleinen Schiff zu den Offshore-Windkraftanlagen gebracht. Die Drohnen sollen für die Kontrollflüge auf dem Schiff starten und landen. Dies hat sich in der teils rauen Nordsee als schwierig erwiesen, da die Bewegungen des Schiffes das Landen für unerfahrene Drohnenpiloten erschweren. Außerdem ist das Starten ab einer gewissen Wellenhöhe gar nicht möglich, da die für universelle Zwecke entworfene Drohne mit den Bewegungen des Schiffes nicht umgehen kann und ein Starten verweigert. Um diese Probleme anzugehen, sollen Drohnenpiloten auf dem Festland im Landen von Drohnen auf einer sich bewegend Plattform geschult werden, damit das Landen auf dem Schiff reibungslos funktioniert. So können auch verschiedene Szenarien auf See erprobt werden, wie zum Beispiel die Bewegung des Schiffes bei starkem Wellengang. Dafür wird eine Bewegungsplattform entwickelt, welche die Bewegungen des Schiffes für unterschiedlich hohe Wellen simulieren können soll. Eine andere Maßnahme ist, vor der Fahrt einschätzen zu können, ob die Drohne auf der zu erwartenden See starten kann oder nicht. Dafür soll die Wettervorhersage für das betreffende Gebiet genutzt werden, um die zu erwartenden Bewegungen des Schiffes zu erhalten.

Sowohl für die Bewegungsplattform als auch für die Vorhersage der Schiffsbewegungen werden Daten zur Bewegung des Schiffes benötigt.

1.2 Aufgabenstellung

Um die aufgezeigten Probleme lösen zu können, wird ein Modell benötigt, welches die Bewegungen des Schiffes bei jeweils unterschiedlichen Wellenhöhen generieren kann. Dafür werden die Eigenschaften der Wellen auf See benötigt. Diese daraus generierten Schiffsbewegungen können dann wiederum in der Bewegungsplattform zur Simulation verwendet werden oder als Indikator dafür genutzt werden, ob die Drohne auf dem Schiff abheben kann und sich eine Fahrt lohnt. Das Ziel dieser Arbeit ist der Vergleich von mehreren Machine-Learning-Modellen, welche die Bewegungen des Schiffes simulieren. Das finale Modell soll einen möglichst guten Zusammenhang zwischen den Wellendaten der Nordsee und den Bewegungsdaten des Schiffes herstellen.

Um diese Aufgabe lösen zu können, gibt es verschiedene Datenquellen, welche den Modellen die Ein- oder Ausgabedaten bereitstellen und mit denen die Modelle trainiert werden sollen.

1. Bewegungsdaten vom Schiff

Die hauptsächliche Datenquelle sind die Messungen der Bewegung des Schiffes. Um die Bewegung des Schiffes nachbilden zu können, werden Daten über sämtliche Bewegungen und Neigungen, also alle sechs Freiheitsgrade des Schiffes benötigt. Diese Daten wurden mit einer Hardware gemessen, welche üblicherweise in Drohnen verbaut wird. Diese Hardware besteht aus verschiedenen Sensoren, verarbeitenden Einheiten und einer Software, welche die Messdaten bereitstellen kann. Diese Hardware wurde mit einiger zusätzlicher Elektronik in einer wetterbeständigen Box auf

dem Schiff montiert und misst Daten von mehreren relevanten Zeitabschnitten über den Tag verteilt. Die Messposition ist dabei auf dem Container auf dem Schiff, da dort auch in Zukunft die Drohnen starten sollen. Die für den Anwendungsfall relevanten Daten werden zu dem Zeitpunkt aufgenommen, wenn das Schiff sich nicht selbstständig fortbewegt, also wenn es nur durch die Wellen bewegt wird. Wenn in der Praxis die Drohnen vom Schiff starten sollen, befindet sich das Schiff auch in diesem Zustand, wo die Bewegung des Schiffs nur von den Wellen beeinflusst wird. Dieser Status ist nicht immer gegeben, daher wurden Informationen über das aktuelle Manöver gesammelt.

2. Manuell aufgenommene Zeitabschnitte

Diese händisch aufgenommenen Informationen beschreiben das aktuelle Manöver des Schiffs und sollen dabei helfen, die relevanten Zeitabschnitte aus den Bewegungsdaten extrahieren zu können. Diese Daten liegen als Excel-Tabelle vor und teilen die Manöver des Schiffs in verschiedene Kategorien ein. Die für den Anwendungsfall relevanten Kategorien sind jene, wo das Schiff sich entweder komplett von den Wellen treiben lässt, oder den Kurs nur leicht beeinflusst (durch Beibehalten der Blickrichtung oder der generellen Position). Diese Kategorien beschreiben ein Manöver, in dem das Schiff nicht oder teilweise nicht aktiv bewegt wird und die meisten Bewegungen von den Wellen verursacht werden. Diese Bewegungen aus diesen Zeitfenstern sollen analysiert und verarbeitet werden. Es wurde allerdings nicht aufgenommen, bei welcher Bewegung die Drohnen starten konnten und bei welcher nicht.

3. Daten des Seegangs

Die Daten über die Höhe und Intensität des Seegangs werden vom Bundesamt für Seeschifffahrt und Hydrographie (BSH) bezogen. In dem neuen INSITU-Portal des BSH lassen sich grundlegende Seegangparameter der verschiedenen Messstationen in der Nord- und Ostsee ausgeben und herunterladen. Für den betreffenden Windpark gibt es eine Messstation, welche Messdaten bereit stellt. Die Messwerte beinhalten verschiedene Parameter im Zeit- und Frequenzbereich. Diese werden im Laufe der Arbeit genauer beschrieben.

Die Anforderungen an das Modell erstrecken sich über die Ein- und Ausgabedaten, deren Formate, eine Definition der Funktion und die daraus möglichen und auch nicht möglichen Anwendungen.

Die Eingabe des Modells sollen verschiedene Parameter der Wellencharakteristik in einem geeigneten Format sein. Die Ausgabe des Modells sollen Schiffsbewegungen sein. Es muss möglich sein, mit der Ausgabe des Modells eine Zeitreihe zu generieren, mit welcher eine Bewegungsplattform die Bewegungen des Schiffs simulieren kann.

Was mit dem Modell beabsichtigt ist, ist eine Regression. Nicht beabsichtigt ist eine Klassifikation von entweder dem aktuellen Manöver oder der Möglichkeit des Startens der Drohne auf dem Schiff. Dafür soll ein Verständnis für die Daten erreicht werden - Wie hängt die Bewegung des Meeres mit der Bewegung des Schiffs zusammen? Außerdem soll eine sogenannte Pipeline erstellt werden, die gegebenen Daten zu verarbeiten. Die besonderen Fragen bezüglich der Daten beziehen sich auf

- die Herkunft der Daten
- die Verarbeitungen der Daten
- die für die Beschreibung der Bewegung relevanten Parameter

1.3 Gliederung der Arbeit

Im Kapitel “Theorie” werden die theoretischen Grundlagen und Konzepte erläutert, die für das Verständnis der nachfolgenden Kapitel erforderlich sind. Dies umfasst die Beschreibung der verwendeten Algorithmen, Modelle und Techniken sowie eine Diskussion vergleichbarer wissenschaftlicher Arbeiten und Studien.

Das anschließende Kapitel beschreibt die Methodik der Forschung. Es werden die Datenquellen, die Datenerhebung und der Aufbau der Daten erläutert sowie die Schritte der Datenvorverarbeitung und des Modelltrainings detailliert dargestellt. Besondere Herausforderungen der Vorverarbeitung und der Umgang damit werden ebenfalls thematisiert.

In Kapitel 4 werden die Ergebnisse der Modellierung und der Experimente präsentiert und interpretiert. Die Leistung der verschiedenen Modelle wird anhand ausgewählter Metriken bewertet und die Ergebnisse werden im Kontext der Zielsetzung der Arbeit diskutiert.

Im letzten Kapitel werden die wesentlichen Erkenntnisse zusammengefasst und im Hinblick auf die Fragestellung bewertet. Zudem werden Probleme und mögliche Verbesserungen mit deren Folgen aufgezeigt. Zuletzt wird ein Ausblick auf mögliche zukünftige Forschungen und Entwicklungen gegeben.

2 Theorie

2.1 Verwandte Arbeiten

In zahlreichen Arbeiten wird mit Wellendaten des Ozeans gearbeitet. Ein Großteil davon beschäftigt sich mit der Vorhersage der See und den Wellen wenige Stunden in der Zukunft oder mit der Generation von Wellendaten aus Winddaten. Es werden außerhalb der etablierten numerischen Wind-Wellen-Modelle neue und bessere Möglichkeiten gesucht, Wellen vorherzusagen. Dafür wird vermehrt auf Modelle des Maschinellen Lernens zurückgegriffen. Von diesen Modellen wird sich eine bessere Vorhersage und ein geringerer Rechenaufwand erhofft.

[Ber+17] beschäftigt sich beispielsweise mit der Generierung der signifikanten Wellenhöhe für die nächsten 0,5 bis 5,5 Stunden in der Zukunft aus den Daten der nahen Vergangenheit und aus Informationen des Windes. Dafür wird ein neuronales Netz und eine Stützvektormaschine verwendet. Auch in [Cal+20] wird die Leistung von vorhandenen Modellen für die Wellenvorhersage mit alternativen Modellen verbessert. Dafür wird ein Random Forest und eine Gradient Boosting Machine mit Entscheidungsbäumen verwendet.

Diese Arbeiten nutzen einen datengetriebenen Ansatz mit Machine-Learning-Modellen und betrachten die Wellen nicht hauptsächlich als Zeitreihe sondern als statistische Parameter, welche die Wellen über einen bestimmten Zeitraum hinweg beschreiben. Diese Ansätze sollen in dieser Arbeit auch verfolgt werden.

2.2 Berechnung der Wellenparameter

Um die Eigenschaften von Wellen zu messen und zu beschreiben, werden überall auf der Welt auf dem Meer Bojen betrieben, welche kontinuierlich die vertikale Bewegung der Meeresoberfläche messen. Für die Beschreibung und Auswertung von Wellen über einen langen Zeitraum von bis zu mehreren Jahren können aufgenommenen Zeitreihen nicht ohne weiteres gespeichert werden, da die Datenmengen sehr groß und unpraktikabel werden. Daher werden Zeitreihendaten der Messstationen umgerechnet in einzelne Werte (Parameter), welche dann einen gewissen Zeitraum beschreiben. Diese Parameter beschreiben dann statistische Kennwerte aus dem Zeit- oder dem Frequenzbereich, welche die Wellen genauso gut beschreiben, wie es auch die Zeitreihendaten würden. Die Daten des InSitu-Portals des BSH wurden schon in solche Parameter umgerechnet und werden als diese bereitgestellt. Im weiteren Verlauf der Arbeit werden dazu noch selbst gemessene Zeitreihen benutzt und in einige dieser Parameter umgerechnet.

Diese Art, die Bewegungen des Meeres darzustellen, wird von verschiedenen Organisationen verwendet, welche eine Langzeitbeobachtung des Meeres oder anderen Systemen durchführen. Der Vorteil ist, dass diese Art der Darstellung einen Zeitraum in einer Datenreihe repräsentiert und dadurch viel weniger Speicherplatz benötigt wird, als die ganze Datenreihe. Dabei enthalten die Parameter alle Informationen, die für die Beschreibung der Meeresbewegungen benötigt werden.

Die Berechnung dieser Daten wird ausführlich in [Wor18] beschrieben. Die Berechnung der Daten vom BSH wurde im Rahmen des Copernicus Marine Service in [TAC20] beschrieben. Die Daten werden in zwei unterschiedlichen Domänen untersucht:

1. Zeitdomäne

In dieser Domäne werden die Zeitreihen unterteilt in einzelne Wellen mittels der “zero upcrossing”-Methode. Hierbei wird die Abgrenzung zwischen den Wellen durch den positiven Nulldurchgang definiert. Eine Welle erstreckt sich zwischen zwei positiven Nulldurchgängen (von negativ zu positiv) und wird durch ihre Dauer (Zeitabstand zwischen den Nulldurchgängen) und Höhe (Differenz zwischen Maximal- und Minimalwert) charakterisiert.




Abbildung 2: Unterteilung nach zero-upcrossing-Methode. Generiert aus eigenen Daten mithilfe der oceanlyz-Bibliothek

Aus der resultierenden Menge an Wellen können verschiedene statistische Kennwerte berechnet werden, welche beispielhaft in Tabelle 1 dargestellt sind. Für den Parameter n wird häufig der Wert 3 genommen, dann werden $H_{1/3}$ und $T_{H1/3}$ häufig als signifikante Wellenhöhe und signifikante Periodendauer bezeichnet

Name	Beschreibung
H	Durchschnittliche Wellenhöhe
H_{max}	Maximale Wellenhöhe in der Zeitreihe
T_z	Durchschnittliche Nulldurchgangs-Wellenperiode
$H_{1/n}$	Durchschnittliche Höhe der $1/n$ höchsten Wellen in der Zeitreihe
$T_{H1/n}$	Durchschnittliche Periodendauer der $1/n$ höchsten Wellen in der Zeitreihe

Tabelle 1: Parameter der Zeitdomäne

2. Frequenzdomäne

Bei dieser Methode wird von der Zeitreihe ein Spektrum mittels FFT-Funktion (Fast Fourier Transform) errechnet. Aus diesem Spektrum lassen sich verschiedene Parameter für den gesamten Beobachtungszeitraum ableiten. Ein wichtiger Teil der Analyse des Spektrums sind die spektralen Momente. Diese spektralen Momente von verschiedenen Ordnungen beschreiben die Fläche unter der Kurve des Frequenzspektrums. Ein spektrales Moment nullter Ordnung beschreibt bei einem Wellenspektrum die gesamte Energie der Wellen. Ein spektrales Moment der i -ten Ordnung wird nach [TAC20] aus einem Spektrum $S(f)$ berechnet mit

$$m_i = \int S(f) f^i df$$

Viele der anderen benutzten Parameter werden aus den spektralen Momenten berechnet, wie

in Tabelle 2 gezeigt wird. Einige Messwerte sind einander oft sehr ähnlich, da sie die gleichen Größen beschreiben, aber auf unterschiedlichen Wegen berechnet wurden. Wenn die Zeitreihe in etwa eine statistische Verteilung darstellt, sind Parameter, welche aus dem Frequenzspektrum abgeleitet werden, anderen statistischen Parametern ähnlich. Das betrifft hier die Parameter H_{m0} und $H_{1/3}$ sowie T_{m02} und T_z

Name	Beschreibung	Berechnung
f_p	Die Frequenz, die dem Peak des Frequenzspektrums entspricht	
T_p	Die Periodendauer, die mit f_p einher geht	$T_p = f_p - 1$
T_{m01}	Die Wellenperiode, die der mittleren Frequenz des Spektrums entspricht	$T_{m01} = m_0/m_1$
T_{m02}	Entspricht theoretisch T_z	$T_{m02} = \sqrt{m_0/m_2}$
H_{m0}	Entspricht theoretisch $H_{1/3}$	$H_{m0} = 4\sqrt{m_0}$

Tabelle 2: Parameter der Frequenzdomäne

2.3 Entscheidungsbäume

Ein Entscheidungsbaum ist eine Methode des maschinellen Lernens zur Darstellung und Lösung von Klassifikations- oder Regressionsproblemen. Ein Entscheidungsbaum als binärer Klassifikator nach [RN12] repräsentiert eine Funktion, die eine Menge von Attributwerten als Eingabe nimmt und eine einzelne Ausgabe (die “Entscheidung”) liefert. Ein Entscheidungsbaum ist hierarchisch strukturiert und besteht aus verschiedenen Knoten (auch zu sehen in Abbildung 3, die weißen Blöcke). An der Spitze steht der Wurzelknoten, von dem aus sich der Baum verzweigt. Dieser ist gleichzeitig auch der Startpunkt. Die inneren Knoten repräsentieren jeweils einen Test auf ein bestimmtes Attribut der Eingabedaten. Von jedem dieser Knoten gehen Zweige ab, die den möglichen Werten oder Wertebereichen des getesteten Attributs entsprechen. Diese Zweige führen entweder zu weiteren inneren Knoten, wo weitere Tests durchgeführt werden, oder zu Blattknoten. Die Blattknoten bilden die unterste Ebene des Baums und enthalten die endgültige Klassifikation oder Entscheidung. Um eine Entscheidung zu treffen, wird ein Datensatz vom Wurzelknoten aus durch den Baum geleitet, wobei an jedem inneren Knoten basierend auf dem Wert des entsprechenden Attributs der passende Zweig gewählt wird. Dieser Prozess wird fortgesetzt, bis irgendein Blattknoten erreicht ist. Der Vorteil von Entscheidungsbäumen ist ihre Interpretierbarkeit und Natürlichkeit für Menschen. Sie können komplexe Entscheidungsprozesse in einer leicht verständlichen Form darstellen.

Bekannte Nachteile von einzelnen Entscheidungsbäumen sind die Neigung zu Überanpassung (overfitting), und eine vergleichsweise geringe Vorhersagegenauigkeit. Um diese Probleme anzugehen, wurden verschiedene Ensemblemethoden entwickelt. Eine solche Methode kombiniert mehrere Entscheidungsbäume, um genauere und robustere Vorhersagen zu treffen.

Eine solche Ensemblemethode ist der Random Forest. Die Konstruktion eines Random Forest erfolgt durch das Erstellen vieler einzelner Klassifikationsbäume, wie in [BC04] beschrieben. Jeder Baum wird mit einer zufälligen Stichprobe aus dem ursprünglichen Trainingsdatensatz erstellt. Bei jedem Knoten wird nur eine zufällige Teilmenge der Eingabevariablen berücksichtigt, was die Diversität zwischen den Bäumen erhöht. Die endgültige Klassifikation eines neuen Objekts erfolgt durch Mehrheitsentscheid aller Bäume im Wald (oder dem Durchschnittswert bei einer Regression). Zu den Hauptvorteilen von Random Forests gehören:




Abbildung 3: Beispiel für Entscheidungsbaum, der ermittelt, ob man auf einen freien Tisch warten soll; aus [RN12]

1. Hohe Genauigkeit im Vergleich zu aktuellen Algorithmen
2. Effiziente Verarbeitung großer Datenmengen
3. Fähigkeit, sehr viele Eingabevariablen zu handhaben
4. Einschätzung der Wichtigkeit von Variablen für die Klassifikation

Random Forests neigen nicht zur Überanpassung, was bedeutet, dass man viele Bäume erstellen kann, ohne die Leistung zu beeinträchtigen.

Eine andere Ensemblemethode des Entscheidungsbaumes ist das Modell “Extra Trees” (Extremely Randomized Trees). Bei Extra Trees werden nicht nur die Merkmale zufällig ausgewählt, sondern auch weitere Aspekte des Baumes werden zufällig gewählt ([dev23]). Dadurch kann Extra Trees in manchen Fällen eine bessere Generalisierung erreichen, insbesondere bei verrauschten Datensätzen.

2.4 Metriken

Um die Leistung von Regressionsmodellen zu bewerten und zu vergleichen, werden verschiedene Metriken verwendet. Diese Metriken sind nützlich, die Genauigkeit der Vorhersagen und mögliche Probleme wie Überanpassung zu bemessen. Einige gängige und in der Arbeit verwendete Metriken sind der mittlere absolute Fehler (Mean Absolute Error, MAE), die mittlere quadratische Abweichung (Mean Squared Error, MSE) und das Bestimmtheitsmaß (R^2 -Wert), wie auch in [CWJ21] und [Sci24] beschrieben ist. Im weiteren Verlauf der Arbeit werden die englischen Begriffe verwendet.

Bei der Bewertung einer Regressionsanalyse werden die vorhergesagten Werte $\hat{Y}_i$ mit den wahren Beobachtungswerten Y_i verglichen. Die Anzahl der behandelten Werte bezeichnet der Wert n .

Mean Absolute Error

Dieser mittlere absolute Fehler beschreibt die durchschnittliche Abweichung der vorhergesagten Werte von der wahren Beobachtung. Dabei werden die Vorzeichen ignoriert und jeder Wert geht gleich stark in den Gesamtwert mit ein.

$$MAE = \frac{1}{n} \sum_{i=1}^n |\hat{Y}_i - Y_i|$$

Diese Metrik hat die Einheit der vorhergesagten Werte und gibt nicht das Vorzeichen der Abweichung an. Der beste Wert dieser Metrik ist null, die Werte können aber auch beliebig groß werden.

Mean Squared Error

Die mittlere quadratische Abweichung beschreibt die durchschnittliche quadrierte Abweichung und hat damit nicht die Einheit der vorhergesagten Werte.

$$MSE = \frac{1}{n} \sum_{i=1}^n (\hat{Y}_i - Y_i)^2$$

Durch die Quadrierung werden Ausreißer viel stärker in die Gesamtwertung mit einbezogen und bewerten das Modell dadurch schlechter als bei dem MAE. Der beste Wert ist hier auch null und die Werte können beliebig groß werden.

R²-Wert

Das Bestimmtheitsmaß beschreibt den Anteil der Varianz, den die vorhergesagten Variablen zu den wahren Beobachtungen haben. Das Maß berechnet sich mit

$$R^2 = 1 - \frac{\sum_{i=1}^n (\hat{Y}_i - Y_i)^2}{\sum_{i=1}^n (Y_i - \bar{Y})^2}$$

mit $\bar{Y} = \frac{1}{n} \sum_{i=1}^n Y_i$, also dem Durchschnitt der wahren Beobachtungen.

Die beste Wert dieser Metrik ist eins, die Werte können auch kleiner sein. Ein Wert von null bedeutet, dass die vorhergesagten Werte dem Durchschnitt der wahren Werte entsprechen. Weiter können die Werte aber auch beliebig negativ werden.

3 Methodik

Nachfolgend wird die Durchführung der Arbeit beschrieben. Dazu werden zunächst alle Datenquellen umfassend erläutert und die Struktur der enthaltenen Daten dargestellt. Anschließend wird die Vorverarbeitung präsentiert und anschließend der Prozess des Modelltrainings beschrieben.

In den folgenden Abschnitten werden einige Begriffe benutzt, welche Lesern, die nicht viel mit der Schifffahrt in Berührung kommen, unter Umständen fremd sein könnten. Alle Bewegungsmöglichkeiten, die ein Körper im dreidimensionalen Raum hat, werden als **Freiheitsgrade** bezeichnet. Im Kontext eines Schiffs, gibt es für einen starren Körper sechs Freiheitsgrade. Diese werden nachfolgend, wie bei Fahrzeugen üblich, auf Englisch bezeichnet, also mit **Roll**, **Pitch** und **Yaw** für die Drehwinkel und **Surge**, **Sway** und **Heave** für die Richtungen.




Abbildung 4: Freiheitsgrade eines Schiffs auf Englisch, aus [Win18]

3.1 Datenbeschreibung

3.1.1 Herkunft

Die Messung der Schiffsbewegung wurde mit einer Hardware durchgeführt, welche üblicherweise in Drohnen eingesetzt wird. Diese wird von der Firma CubePilot hergestellt und beinhaltet verschiedene Subsysteme mit ihren eigenen Sensoren. Diese sind bei [Cuba] und [Cubb] beschrieben. Die Trägerplatte hat für die Arbeit keine relevanten Sensoren.

Modul	Inhalt	Beschreibung	Erklärung
Cube Orange +	ICM42688 (Isolated)	IMU1 (Inertiale Messeinheit)	3-Achsen Gyroskop 3-Achsen Beschleunigungssensor
	ICM20948 or ICM42688 (Isolated)	IMU2 (Inertiale Messeinheit)	3-Achsen Gyroskop 3-Achsen Beschleunigungssensor 3-Achsen Kompass (nur ICM20948)
	ICM20649 or ICM45686 (Fixed)	IMU3 (Inertiale Messeinheit)	3-Achsen Gyroskop 3-Achsen Beschleunigungssensor
	2x MS5611	Barometer	Barometrischer Drucksensor
Here 3+	ICM20948	IMU (Inertiale Messeinheit)	3-Achsen Gyroskop 3-Achsen Beschleunigungssensor 3-Achsen Kompass
	NEO-M8P	GNSS Modul	Globales Navigationssatellitensystem

Tabelle 3: Beschreibung des Inhalts der Hardware

Die beschriebene Hardware wurde in einer wasserdichten Box mit einer Stromversorgung montiert. Sobald das Gerät eingeschaltet wird, beginnt es mit der Messung. Dabei werden binäre Logdateien im Gerät gespeichert. Die Messungen erfolgten über längere Zeiträume, teilweise mehrmals pro Messtag für einige Minuten bis wenige Stunden. Während dieser Messungen führte das Schiff verschiedene Manöver durch, von denen nicht alle für die Auswertung relevant sind. Zu den Manövern und den jeweiligen Zeitpunkten wurden händisch Notizen gemacht, die anschließend in eine Excel-Tabelle übertragen wurden. Die wasserdichte Box befindet sich bei jeder Messung auf dem Container des Schiffs (siehe Abbildung 5). Die Ausrichtung der Hardware in der Box ist in Blickrichtung des Schiffs. Dieser Standort ist zwar nicht relevant für die Werte der Drehachsen, aber für die erfassten Beschleunigungen.



Abbildung 5: Schiff Windea Four [KG24] mit eingezeichneter Position der Messbox

Die Messwerte der See sind Teil des Copernicus Marine Service. Hierbei werden die Messwerte vieler europäischer Institutionen gebündelt. Das Portal “In Situ TAC” (In Situ Thematic Assembly Center) ermöglicht einen zuverlässigen Zugang zu diesen Daten. Der Fokus liegt auch auf Qualitätskontrolle und Vereinheitlichung der Daten, wie bei [Sita], der offiziellen Webseite, beschrieben ist. Das BSH betreibt verschiedene Messeinrichtungen in Nord- und Ostsee für den Copernicus Marine Service. Zwei dieser Einrichtungen befinden sich im Gebiet der behandelten Windfarm “Nordsee One”. Die gemessenen Daten werden in einige der Parameter umgerechnet, welche über das Copernicus-Projekt vorgegeben sind. Dafür wird größtenteils die vertikale Bewegung der See benutzt, für einige Parameter auch die horizontalen Bewegungen. Die Daten sind laut des Dashboards [Sitb] für den gesamten Zeitraum zwischen Februar 2018 und heute verfügbar.

3.1.2 Struktur

Daten zur Schiffsbewegung

Die Software auf der Drohnenhardware, Ardupilot, stellt viele verschiedene Parameter in den Logs bereit. Nicht alle davon haben einen brauchbaren Inhalt, da viele zusätzlichen Module in den Logs berücksichtigt werden, welche aber nicht als Hardware angeschlossen sind. Eine Auswahl der verfügbaren Messwerte wird in Tabelle 4 genauer dargestellt.

Duplikate in den Datensätzen könnten auf ein mögliches Oversampling (Überabtastung) hinweisen, also darauf, dass der Sensor die Daten nicht so schnell misst, wie sie abgespeichert werden. Ein starkes Oversampling deutet darauf hin, dass die angegebene Frequenz anders zu betrachten ist, da die

Name	Beschreibung (laut [Tea])	Frequenz [Hz]	Dauer [ms]	Duplikate
ATT	IMU accelerometer data	400,0	2,5	34%
GPA	GPS accuracy information	5,0	200,0	0%
GPS	Information received from GNSS	5,0	200,0	0%
IMU0	Inertial Measurement Unit data	25,0	40,0	0%
IMU1	Inertial Measurement Unit data	25,0	40,0	0%
IMU2	Inertial Measurement Unit data	25,0	40,0	0%
MAG0	Information received from compasses	10,0	100,0	0%
MSG	Textual messages	0,4	2708,0	0%
RATE	Desired and achieved vehicle attitude rates	400,0	2,5	0%
XKF2	EKF3 estimator secondary outputs	75,0	13,3	99%

Tabelle 4: Ausgewählte Messreihen mit selbst berechneten Kennwerten

Informationen dann eine geringere tatsächliche Frequenz haben. In der Messreihe XKF2 sind fast nur Duplikate erkennbar. Bei näherer Betrachtung der Daten ist ersichtlich, dass die meisten Daten entweder den Wert null haben oder sich wiederholen. Damit ist diese Messreihe vorerst unbrauchbar. Für die Beschreibung der Bewegung des Schiffs sind Parameter wie ATT, RATE, MAG und IMU von Interesse.

Name	Messwert	Einheit	Beschreibung
ATT	TimeUS	μs	Time since system startup
	Roll	deg	achieved vehicle roll
	Pitch	deg	achieved vehicle pitch
	Yaw	degheading	achieved vehicle yaw
RATE	TimeUS	μs	Time since system startup
	R	deg/s	achieved vehicle roll rate
	P	deg/s	vehicle pitch rate
	Y	deg/s	achieved vehicle yaw rate
MAG	TimeUS	μs	Time since system startup
	MagX	mGauss	magnetic field strength in body frame
	OfsX	mGauss	magnetic field offset in body frame
	MOX	mGauss	motor interference magnetic field offset in body frame
IMU	TimeUS	μs	Time since system startup
	GyrX	rad/s	measured rotation rate about X axis
	GyrY	rad/s	measured rotation rate about Y axis
	GyrZ	rad/s	measured rotation rate about Z axis
	AccX	m/s ²	acceleration along X axis
	AccY	m/s ²	acceleration along Y axis
	AccZ	m/s ²	acceleration along Z axis

Tabelle 5: Detaillierte Analyse relevanter Messreihen, aus [Tea]

Wie in der Tabelle 5 dargestellt, enthält der Parameter MAG keine für die Bewegung des Schiffs interessanten Messwerte. Die anderen Parameter ATT, RATE und IMU haben jedoch relevante Messwerte, allerdings in unterschiedlichen Einheiten und Frequenzen. In den Messreihen sind dabei jeweils Rotationen vorhanden, während die linearen Bewegungen nur einmal in Form von Beschleunigungen in IMU erfasst wurden. Dies suggeriert einen Beschleunigungssensor als Datenquelle für die Messreihe.

Wellendaten vom BSH

Die bereitgestellten Daten werden in weit verbreiteten Datenformaten zur Verfügung gestellt, wobei

in diesem Fall das CSV-Datenformat zum Einsatz kommt. Alle Messwerte werden in einem Intervall von einer Minute ausgegeben, was bedeutet, dass für jede Minute ein Set an Messwerten von der Messstation vorliegt. Die ausgegebenen Daten stellen ausschließlich berechnete Kennwerte der Wellen dar und beinhalten keine Zeitreihen. Diese Kennwerte umfassen sowohl physikalische Größen als auch statistische Kennwerte. Diese Kennwerte werden in der Tabelle 6 aufgezeigt.

Messstation	Analyse-Art	Messwert	Einheit	Beschreibung InSitu Portal
Nordsee One	Zeitbereich	SLEV_H1	m	Average height over last 1 minute
	Zeitbereich	SLEV_H10	m	Average height over last 10 minutes
	Zeitbereich	VAVH	m	Durchschnittliche Höhe der 33% höchsten Wellen (H1/3)
	Frequenzbereich	VHM0	m	Spektrale signifikante Wellenhöhe (Hm0)
	Zeitbereich	VHZA	m	Durchschnittliche Wellenhöhe (H _{zm})
	Frequenzbereich	VPED	deg	Peak Wellenrichtung (Dirp)
	Frequenzbereich	VTM02	s	Spektrale Momente (0,2) Wellenperiode (T _{m02})
	Frequenzbereich	VTPK	s	Peak Wellenperiode (T _p)
	Zeitbereich	VZMX	m	Maximale Wellenhöhe (H _{max})

Tabelle 6: Inhalt der Messdaten vom InSitu-Portal

Die Parameter, welche in den Messdaten enthalten sind, werden so berechnet, wie schon in Kapitel 2.2 beschrieben wurde.

3.1.3 Vorverarbeitung

Die Daten, die benutzt werden, um dieses Problem zu lösen, kommen aus verschiedenen Quellen und durchlaufen teilweise gleiche und teilweise unterschiedliche Verarbeitungsschritte, bis sie zum Einsatz kommen können. In diesem Prozess werden einige Daten auch in anderen integriert oder verarbeitet. Für diese Aufgabenstellung wird das schematisch in Abbildung 6 dargestellt.

Die in der Abbildung genannten Verarbeitungsschritte wurden für diesen Anwendungsfall ausgesucht und werden im folgenden nacheinander für jeden Schritt erklärt. Dabei ist alles, wenn nicht anders angegeben, in der Programmiersprache Python umgesetzt und gegebenenfalls wurden Bibliotheken von Dritten benutzt.

1. In der Bereitstellung der Daten werden die Bewegungsdaten des Schiffes zunächst aus einem binären Datenformat, welches die Drohnenhardware liefert, in einzelne CSV-Dateien umgewandelt. Dafür wird die Bibliothek “pybinlog” verwendet. Diese kann in der Komandozeile ausgeführt werden und speichert die CSV-Dateien in einem angegebenen Ordner. Dabei hat jeder gespeicherte Messwert eine eigene CSV-Datei (Beispiel siehe Tabelle 4).
Bei den maritimen Messdaten vom BSH werden die CSVs der jeweiligen Messtage aus dem Online-Portal heruntergeladen.
2. Für das Einlesen der Daten werden alle Datenquellen mittels der Pandas-Bibliothek eingelesen und als DataFrames weiter verarbeitet. Bei den Manöver-Daten benötigt Pandas noch die Bibliothek openpyxl, da diese mit Excel-Tabellen umgehen kann.




Abbildung 6: Schaubild Datenverarbeitung

Bei den Schiffsbewegungsdaten werden aus den vielen möglichen die Messreihen “IMU0” verwendet, da diese alle Freiheitsgrade beinhaltet. Außerdem wird ein einzelner Eintrag aus den “GPS”-Daten benutzt, um die korrekte Zeit zu berechnen.

3. In der Bereinigung der Daten wird zunächst bei den Schiffsbewegungsdaten ein Zeitstempel an die eingelesenen Daten angefügt, da alle Datenlogs nur eine Zeitangabe in Mikrosekunden seit Start des Systems haben. Dafür wird mit Hilfe des GPS-Logs die GPS-Zeit in UTC-Zeit umgewandelt. Anschließend kann man dann für alle Daten die UTC-Zeit in der korrekten Zeitzone berechnen lassen. Für diese Berechnungen werden die Bibliotheken “datetime” und “astropy” verwendet. Die Zeit wird dabei auf ganze Minuten gerundet, damit sie sich zu einem späteren Zeitpunkt mit den Zeitstempeln aus den BSH-Daten vergleichen lassen.

Bei den BSH-Wellendaten werden die Daten auf Plausibilität und Qualität gefiltert. Einige Parameter der BSH-Wellendaten haben in einigen Messtagen keine verwertbaren Daten, so dass diese rausgefiltert werden. Außerdem haben die Daten von Haus aus eine eingebaute Qualitätskontrolle, wo jedem Wert ein Qualitätsniveau zugeordnet wird. Die möglichen Werte sind

in Tabelle 7 aufgezeigt. Daten, die ein Niveau über 2 haben, werden entfernt.

Code	Meaning
0	No QC was performed
1	Good data
2	Probably good data
3	Bad data that are potentially correctable
4	Bad data
5	Value changed
6	Not used
7	Nominal value
8	Interpolated value
9	Missing value

Tabelle 7: Qualitätsparameter der BSH-Daten, nach [TAC20]

In den Manöver-Daten werden nur jene Manöver ausgewählt und übernommen, welche für die Auswertung relevant sind, hier sind es die Manöver “idle”, “hold_position” und “hold_yaw”. Bei diesen Manövern bewegt sich das Schiff größtenteils durch die vorherrschenden Wellen und nicht durch den eigenen Antrieb. Diese Option ist auch einfach zu ändern und so können schnell andere Manöver untersucht werden.

4. In dem nächsten Abschnitt werden die Daten ausgeschnitten und reorganisiert. Dafür werden die relevanten Zeitabschnitte aus den Manöver-Daten auf die Schiffsbewegungsdaten angewendet und damit die relevanten Zeiten aus den Bewegungsdaten ausgeschnitten. Dann bleiben nur noch die für die Analyse relevanten Abschnitte übrig und können weiter verarbeitet werden. Zusätzlich werden diese relevanten Abschnitte weiter unterteilt in eine Länge von je einer Minute, damit daraus dann im nächsten Schritt Kennwerte berechnet werden können, welche genau eine Minute abbilden.
5. Um die Daten verwenden zu können, müssen die Einheiten umgerechnet werden. Dies ist auch in dem Leitfaden [Wor18] so beschrieben, dass die Zeitreihendaten als Distanz verarbeitet werden. Da die Daten vom IMU teilweise Beschleunigungen beschreiben, haben diese auch die Einheit m/s^2 . Dementsprechend müssen die Daten doppelt integriert werden. Die Daten eines anderen Parameters, welche beispielsweise Geschwindigkeiten beschreiben, müssen lediglich ein Mal integriert werden, um die Einheit m zu beschreiben. Bei der Integration fällt jedoch auf, dass vor allem die doppelt integrierte Zeitreihe deutlich von den ursprünglichen Werten und dem erwarteten Verlauf abweicht.

Die beiden Frequenzspektren (Abbildung 7), zeigen dieselben Daten mit unterschiedlicher Darstellungsart. Das erste Spektrum zeigt einen sehr hohen Datenpunkt bei 0Hz, welcher in dem anderen Bild auf der logarithmischen Frequenzachse nicht auftritt. Dies liegt daran, dass dies die Frequenz bei exakt 0 Hz darstellt und diese nicht auf einer logarithmischen Achse dargestellt werden kann. In der Praxis bezeichnet die Amplitude bei 0Hz den sogenannten Gleichanteil des Signals, also die Verschiebung auf der Y-Achse. Der Grund ist, dass der Wert des Freiheitsgrades Heave von der Erdbeschleunigung beeinflusst wird, welche normalerweise $-9,81m/s^2$ beträgt. Auch die anderen Freiheitsgrade haben einen Gleichanteil, dieser fällt aber deutlich geringer aus. Weiterhin gibt es lokale Maxima bei ca. 0,5Hz, 3,5Hz und 6,5Hz. In der Abbildung 8 kann




Abbildung 7: Frequenzspektrum der Zeitreihe des Freiheitsgrades Heave in zwei Darstellungen




Abbildung 8: Doppelte Integration einer Zeitreihe des Freiheitsgrades Heave

man das Problem mit der Integration gut erkennen. Die ursprünglichen Daten sind deutlich verrauscht und bewegen sich um die Nulllinie. Die Daten der ersten Integration sind gar nicht mehr verrauscht und bewegen sich teilweise auch unterhalb der Nulllinie. Die doppelt integrierten Daten dagegen bewegen sich deutlich über der Nulllinie und sind nicht mehr mit dem Kontext zu vereinbaren.

Der Grund für diese unlogische Bewegung der Daten ist, dass Beschleunigungssensoren immer einen gewissen Drift haben. Dieser Drift sorgt dafür, dass der Nullpunkt des Sensors sich verschiebt und die neu gemessenen Daten dann entgegen des vorherigen Nullpunktes verschoben sind. Diese Verschiebung ist wie sehr niederfrequentes Rauschen und lässt sich nur schwer vermeiden oder rechnerisch entfernen. In höher entwickelten Systemen werden ein oder mehrere Sensoren zusätzlich genommen, um durch Vergleich der Daten den Drift zu entfernen. Dies ist bei dieser vergleichsweise einfachen und zeitlich begrenzten Arbeit nicht möglich. Anstatt dessen werden Filter benutzt, um verschiedene Frequenzen im Frequenzspektrum zu entfernen. Dies hat das Ziel, das hoch- und niederfrequente Rauschen zu entfernen oder zumindest zu vermindern. Um das zu erreichen wird ein Hoch- und ein Tiefpassfilter benutzt, um nicht relevante Frequenzen zu entfernen. Das Ergebnis dieser Filterung kann in den Abbildungen 9 und 10 gesehen werden. Die gefilterten Daten zeigen schon im Frequenzspektrum (Abbildung 9) eine große Veränderung, da alles über 2Hz entfernt wurde. Einen so großen Teil des Spektrums kann man entfernen, da im




Abbildung 9: Frequenzspektrum der Zeitreihe des Freiheitsgrades Heave nach der Anwendung der Filters in zwei Darstellungen




Abbildung 10: Anwendung der Filter auf die Zeitreihe Heave (Grenzfrequenz Hochpass: 0.18Hz; Grenzfrequenz Tiefpass: 2Hz)

Leitfaden [Wor18] auf Seite 17 die typische Form eines Wellenspektrums beschrieben ist. Diese beschreibt einen steilen Anstieg in den niedrigen Frequenzen und danach eine durchgehende Abflachung der Intensität, welche mit diesem Schwellwert erreicht werden kann. Außerdem wurde der Anfang des Spektrum etwas modifiziert, sodass der Gleichwert und niederfrequentes Rauschen möglichst entfernt werden. In der danach wieder rücktransformierten Zeitreihe (Abbildung 10) kann man schnell erkennen, dass die Filter die Störungen für diese Zeitreihe größtenteils beheben konnten. Das originale Signal ist gar nicht mehr verrauscht und die doppelt integrierte Zeitreihe liegt fast auf der Nulllinie.




Abbildung 11: Anwendung der Filter auf die Zeitreihe Surge (Grenzfrequenz Hochpass: 0.18Hz; Grenzfrequenz Tiefpass: 2Hz)

Allerdings sind die Parameter für den Hoch- und Tiefpassfilter nicht bei allen Daten einheitlich. Wenn man einen anderen Zeitabschnitt oder Freiheitsgrad wählt und dort mit den selben Grenzfrequenzen die Daten filtert, wird man ein anderes Ergebnis bekommen. Dies ist auch in Abbildung 11 zu sehen. Um die Daten komplett aufzubereiten, müsste für jeden Datenabschnitt eigene Grenzfrequenzen für den Tiefpass und vor allem den Hochpass gefunden werden. Da auch

dies nicht im Arbeitsumfang für diese Arbeit liegt, wird die Herangehensweise hinsichtlich der Einheiten geändert. Es werden im Folgenden nur noch die Geschwindigkeiten für die Berechnung der Wellenparameter benutzt, da diese bei unterschiedlichen Grenzfrequenzen stabiler um die Nulllinie herum liegen und damit nicht einzeln bearbeitet werden müssen. Es werden dann im Laufe der Arbeit als gut befundenen Grenzfrequenzen für Hoch- und Tiefpass verwendet, um die Zeitreihen zu optimieren (Grenzfrequenz Hochpass: 0.1Hz; Grenzfrequenz Tiefpass: 2Hz). Nun sind die Daten soweit es möglich ist bereinigt und korrigiert, sodass aus ihnen brauchbare Features berechnet werden können.

6. Bei der Feature-Extraktion werden aus den aufgeteilten Datenabschnitten der Schiffsbewegungsdaten die charakteristischen Wellenparameter berechnet, welche auch in den BSH-Daten vorkommen. Dafür wird die Bibliothek `oceanlyz` verwendet. Die Parameter, die von der Bibliothek berechnet werden können sind:

- H_s - Significant Wave Height [m]
- H_{m0} - Zero-Moment Wave Height [m]
- H_z - Zero Crossing Mean Wave Height [m]
- T_{m02} - Wave Period from m02 [second], Mean Zero Crossing Period
- T_p - Peak Wave Period [second]
- T_{m01} - Wave Period from m01 [second], Mean Wave Period

Diese Parameter lassen sich auch alle in den BSH-Daten finden, allerdings sind das nicht alle Daten, die das BSH bereitstellt. Außerdem gibt es auch noch Messwerte, die die Bibliothek berechnen kann, die wiederum nicht in den BSH-Daten auftauchen. Diese sind:

- T_s - Significant Wave Period [second]
- T_z - Zero Crossing Mean Wave Period [second]
- f_p - Peak Wave Frequency [Hz]

Diese Daten werden alle berechnet und zusammen mit den Zeitinformationen wieder ausgegeben. Jetzt sind die Daten bereit für den letzten Schritt.

7. Im letzten Schritt werden die Daten nochmal reorganisiert. Hier werden die BSH-Wellendaten und die berechneten Parameter der Schiffsbewegung zusammen gefügt. Beide Datensätze haben einen Zeitstempel und auf dieser Spalte werden die beiden Daten kombiniert, sodass in einer Zeile alle Daten zu dem Zeitpunkt gesammelt sind. Bei diesem Vorgang fallen auch alle BSH-Daten weg, welche kein Gegenstück in den Schiffsbewegungsdaten haben. Als letztes werden alle Messtage, welche einzeln diesen Prozess durchlaufen, in einem großen Datensatz gesammelt. Nun sind die Daten bereit, in einem Machine-Learning Modell benutzt zu werden.

3.2 Modelltraining

3.2.1 Herangehensweise

Für das Training des Modells wurden die gesammelten Informationen in einer großen Tabelle zusammengetragen und wie beschrieben aufbereitet. Diese Tabelle umfasst neun Eingabevariablen, die aus

den BSH-Daten stammen, sowie sechs Mal neun Ausgabevariablen, die mithilfe der `oceanlyz`-Bibliothek aus den gemessenen Schiffsbewegungen berechnet wurden. Dies sind jeweils neun Ausgabevariablen für die sechs Freiheitsgrade, welche in dem System aufgezeichnet wurden. Insgesamt enthält der Datensatz 387 Einträge aus den bisherigen Messungen.

Aufgrund der überschaubaren Datenmenge bietet sich die Möglichkeit, verschiedene Modellansätze zu erproben. Der Trainingsprozess für ein einzelnes Modell wird voraussichtlich zwischen 0,5 und 2 Sekunden in Anspruch nehmen. Diese relativ kurze Trainingszeit ermöglicht es, sämtliche in der `scikit-learn` Bibliothek verfügbaren Regressoren zu testen und zu vergleichen. Um die Qualität der Modelle zu beurteilen, werden verschiedene Metriken herangezogen. Diese sind in Kapitel 2.4 beschrieben.

Zusätzlich zu den selbst ausgewählten Modellen wird die Bibliothek `pycaret` genutzt, um eine alternative Auswahl von Modellen zu evaluieren. Dies ermöglicht einen breiteren Vergleich und Beurteilung der Modellleistungen. Nachdem ein Überblick über die oberflächliche Performance der verschiedenen Modelle gewonnen wurde, werden die vielversprechendsten Kandidaten einer tiefergehenden Analyse unterzogen. Hierfür kommt eine Rastersuche (Grid Search) zum Einsatz, um die Hyperparameter der Modelle zu optimieren. Mit den optimierten Hyperparametern erfolgt ein erneuter Vergleich dieser ausgewählten Modelle. Basierend auf diesen Ergebnissen kann schließlich eine Entscheidung für das am besten geeignete Modell getroffen werden.

Da das vorliegende Problem mehrere Zielvariablen umfasst, ergibt sich die Frage nach dem optimalen Umgang mit dieser Situation. Es existieren Regressionsmodelle, die in der Lage sind, mit mehreren Ausgabevariablen gleichzeitig zu arbeiten. Allerdings gibt es auch Modelle, die auf eine einzelne Zielvariable beschränkt sind. `Scikit-learn` bietet spezielle Klassen an, die eine Lösung für dieses Problem bieten. Zwei Beispiele hierfür sind der `MultiOutputRegressor` und die `RegressorChain`. Diese Klassen ermöglichen es, auch Modelle mit Einzelausgaben für Mehrfachausgaben zu nutzen. Eine alternative Herangehensweise besteht darin, den zuvor beschriebenen Ansatz für jede Zielvariable separat durchzuführen. Dies könnte potenziell zu einem optimal angepassten Ergebnis für jede einzelne Ausgabevariable führen.

Um die Effektivität beider Methoden zu evaluieren und die bestmögliche Lösung zu finden, ist geplant, im Verlauf des Trainingsprozesses sowohl den Mehrfachausgabe-Ansatz als auch die separate Modellierung für jede Zielvariable zu testen. Diese vergleichende Analyse wird es ermöglichen, die Vor- und Nachteile beider Strategien zu beurteilen und die für diesen spezifischen Anwendungsfall am besten geeignete Methode zu finden.

3.2.2 Allgemeiner Modellvergleich

In einem ersten Screening sollen zehn verschiedene Modelle testweise mit dem vorhandenen Datensatz trainiert werden. Die Leistung jedes Modells wird anschließend anhand der zuvor festgelegten Metriken bewertet. Dabei sollen zwei unterschiedliche Ansätze verfolgt und verglichen werden. Im ersten Ansatz wird jeder Freiheitsgrad als Ganzes trainiert, wobei verschiedene Modelle zum Einsatz kommen, die mehrere Zielvariablen gleichzeitig unterstützen. Die Ergebnisse dieses Ansatzes sind in Abbildung 12 visualisiert. Der zweite Ansatz besteht darin, jeden Parameter eines Freiheitsgrades einzeln mit den verschiedenen Modellen zu trainieren. Einige Resultate dieser Methode sind in den Abbildungen 13 und 14 dargestellt.

Zusätzlich zu den oben genannten Methoden wurden auch Tests mit der Bibliothek `pycaret` durch-




Abbildung 12: Test-Training auf ganzen Freiheitsgrad




Abbildung 13: Test-Training auf einzelne Parameter der Heave-Bewegung




Abbildung 14: Test-Training auf einzelne Parameter der Sway-Bewegung

geführt. Das Ergebnis eines typischen Testdurchlaufs mit dieser Bibliothek ist in Tabelle 8 zu sehen. Diese Analyse ermöglicht es, einen anderen Blick auf die verfügbaren Modelle zu erhalten und eine Einschätzung zu haben, ob die eigene Auswahl der Modelle sinnvoll ist.

Die Analyse der Ergebnisse des Ansatzes mit mehreren Zielvariablen in Abbildung 12 offenbart einige

	Model	MAE	MSE	RMSE	R2	RMSLE	MAPE	TT (Sec)
rf	Random Forest Regressor	0.0504	0.0046	0.0669	0.9266	0.0308	0.0448	0.2770
et	Extra Trees Regressor	0.0503	0.0046	0.0673	0.9262	0.0307	0.0443	0.1720
gbr	Gradient Boosting Regressor	0.0529	0.0050	0.0702	0.9194	0.0325	0.0474	0.0680
lightgbm	Light Gradient Boosting Machine	0.0551	0.0053	0.0720	0.9162	0.0330	0.0491	0.1020
ada	AdaBoost Regressor	0.0637	0.0062	0.0784	0.9015	0.0363	0.0576	0.1000
lr	Linear Regression	0.0703	0.0072	0.0846	0.8838	0.0390	0.0631	0.0350
br	Bayesian Ridge	0.0707	0.0074	0.0858	0.8810	0.0396	0.0634	0.0280
huber	Huber Regressor	0.0719	0.0077	0.0876	0.8757	0.0405	0.0644	0.0530
ridge	Ridge Regression	0.0730	0.0078	0.0884	0.8741	0.0408	0.0655	0.0310
dt	Decision Tree Regressor	0.0605	0.0084	0.0903	0.8655	0.0413	0.0536	0.0350
lar	Least Angle Regression	0.0854	0.0108	0.1036	0.8280	0.0483	0.0775	0.0310
knn	K Neighbors Regressor	0.1369	0.0350	0.1830	0.4316	0.0838	0.1246	0.0410
en	Elastic Net	0.1948	0.0589	0.2407	0.0694	0.1096	0.1722	0.0290
omp	Orthogonal Matching Pursuit	0.1944	0.0589	0.2405	0.0692	0.1096	0.1719	0.0270
lasso	Lasso Regression	0.1953	0.0590	0.2410	0.0688	0.1097	0.1725	0.0280
llar	Lasso Least Angle Regression	0.1953	0.0590	0.2410	0.0688	0.1097	0.1725	0.0280
dummy	Dummy Regressor	0.2057	0.0647	0.2537	-0.0188	0.1151	0.1815	0.0160
par	Passive Aggressive Regressor	0.2082	0.0703	0.2561	-0.0879	0.1253	0.1949	0.0290

Tabelle 8: Beispiel-Ausgabe der pycaret-Bibliothek zur Analyse der Parameter der Yaw-Bewegung

interessante Erkenntnisse: Zunächst fällt auf, dass sowohl MAE als auch MSE bei vielen Modellen sehr nahe bei 0 liegen. Dies deutet darauf hin, dass die meisten getesteten Modelle grundsätzlich eine akzeptable Leistung zeigen. Bemerkenswert ist, dass der MSE häufig niedriger ausfällt als der MAE. Diese Beobachtung lässt darauf schließen, dass die Modelle generell nicht viele Ausreißer produzieren, da der MSE Ausreißer stärker gewichten würde. Die R^2 -Metrik zeigt deutlichere Unterschiede zwischen den verschiedenen Modellen auf. Hierbei ist zu beachten, dass ein Wert von 1 bei dieser Metrik das Optimum darstellt, sodass rote Felder in der Visualisierung besser zu bewerten sind als gelbe. Bei der Betrachtung aller Modelle stechen vier Modelle heraus:

1. Random Forest
2. Extra Trees
3. AdaBoost (in einem Multioutput-Wrapper)
4. GradientBoosting (ebenfalls in einem Multioutput-Wrapper)

Diese vier Modelle zeigen zwar unterschiedliche Leistungen zwischen den verschiedenen Freiheitsgraden, sind aber durchweg besser als die anderen getesteten Modelle. Im Gegensatz dazu zeigt beispielsweise die Lasso Regression durchgängig schlechte Ergebnisse, was sich auch in den entsprechenden MSE- und MAE-Werten widerspiegelt. Bei dem Vergleich der einzelnen Freiheitsgrade untereinander fallen ebenfalls Unterschiede auf: Die Freiheitsgrade Roll und insbesondere Sway zeigen bei allen Modellen vergleichsweise schlechte Ergebnisse. Während MSE und MAE noch akzeptable Werte aufweisen, fällt der R^2 -Wert deutlich schlechter aus als bei den anderen Freiheitsgraden. Im Gegensatz dazu weisen Surge und Heave die besten Ergebnisse auf, besonders bei den vier zuvor hervorgehobenen Modellen.

Bei dem Ansatz, bei dem jeder Parameter einzeln trainiert wird, gibt es zwei Beispiele aus dem Datensatz zu sehen. Dies sind die Ergebnisse zu dem Freiheitsgrad Sway und Heave (zu sehen in den Abbildungen 13 und 14). Bei den Daten zu Heave lassen sich viele Parallelen zu den vorherigen Beobachtungen erkennen: MSE und MAE zeigen oft ähnliche Tendenzen, wobei der MAE häufig etwas höher liegt als der MSE. Im Gegensatz zur vorherigen Analyse sind die Werte jedoch nicht

mehr durchgängig sehr niedrig. Besonders auffällig ist dies beim Parameter T_z , wo beide Werte höher ausfallen als bei anderen Parametern. Außerdem hat das neuronale Netz große Unterschiede zwischen einigen Werten. So hat es bei einigen Parametern bemerkenswert schlechte, bei anderen aber eher durchschnittliche Ergebnisse. Der R^2 -Wert offenbart erneut die deutlichsten Unterschiede zwischen den Modellen. Die vier Modelle, die sich bereits zuvor als leistungsstark erwiesen haben, stechen auch hier heraus. Diese Modelle zeigen konsistent die beste Performance innerhalb jedes Parameters. Selbst in Fällen, wo ihre Leistung deutlich abfällt, schneiden sie immer noch besser oder zumindest gleichwertig zu den anderen Regressionsmodellen ab. Bei einem Vergleich der einzelnen Parameter fallen T_z und H_z durch ihre vergleichsweise schlechten Ergebnisse auf:

- H_z weist gute Werte für MSE und MAE auf, zeigt jedoch schlechte Ergebnisse beim R^2 -Wert
- T_z schneidet bei allen drei Metriken vergleichsweise schlecht ab

Bei der Betrachtung der Daten zu Sway in Abbildung 14 wird deutlich, dass das Training weniger erfolgreich verlaufen ist als bei den zuvor analysierten Fällen. Zwar gibt es bei einigen Parametern, insbesondere f_p und T_{m02} , durchaus gute Werte für MAE und MSE. Allerdings fällt auf, dass die R^2 -Metrik durchweg niedriger ausfällt als bei allen anderen untersuchten Freiheitsgraden. Dies ist ein deutlicher Indikator dafür, dass die Modelle Schwierigkeiten haben, die Varianz in den Daten dieses Freiheitsgrades zu erklären. Allerdings zeigt sich auch hier ein konsistentes Muster: Die vier bereits zuvor identifizierten Modelle - Random Forest, Extra Trees, AdaBoost und GradientBoosting - erzielen auch in diesem Szenario etwas bessere Ergebnisse als die anderen getesteten Modelle. Diese Beobachtungen werden durch die Ergebnisse für Sway in dem Ansatz für mehrere Parameter in Abbildung 12 bestätigt. Auch dort zeigt Sway ähnlich schlechte Ergebnisse, was auf eine generelle Schwierigkeit bei der Modellierung dieses Freiheitsgrades hindeutet.

Nach den initialen Trainings und der umfassenden Analyse der Ergebnisse kristallisieren sich vier Modelle als besonders vielversprechend heraus:

1. Random Forest
2. Extra Trees
3. AdaBoost
4. GradientBoosting

Diese Auswahl wird durch die Analyse mit der pycaret-Bibliothek bestätigt, die keine zusätzlichen Modelle mit besseren Leistungen identifizieren konnte. Für die weitere, vertiefte Untersuchung und Optimierung wird jedoch eine leichte Anpassung vorgenommen: Der AdaBoost Regressor wird aus der weiteren Betrachtung ausgeschlossen. Diese Entscheidung basiert auf der Tatsache, dass AdaBoost, ähnlich wie die anderen drei Modelle, eine Ensemblemethode ist und ebenfalls mit Entscheidungsbäumen arbeitet. Da alle vier Modelle vergleichbare Ergebnisse liefern, erscheint es sinnvoll, die Untersuchung auf drei dieser Modelle zu beschränken. Zusätzlich werden noch zwei weitere Modelle tiefer betrachtet. Das ist einmal das neuronale Netz in Form des MLPRegressor. Neuronale Netze sind für ihre Flexibilität und Leistungsfähigkeit bekannt, erfordern jedoch oft eine sorgfältige Parameteroptimierung. Außerdem wird das lineare Regressionsmodell weiter untersucht, um einen Referenzwert

zu haben.

Eine wichtige Erkenntnis aus den vorangegangenen Test-Trainings ist die Konsistenz der Modellleistungen über die zwei Trainingsansätze hinweg. Es zeigte sich, dass die Leistung der Modelle relativ stabil blieb, unabhängig davon, ob jeder Parameter einzeln trainiert oder der gesamte Freiheitsgrad als Einheit betrachtet wurde. Es gab keine signifikanten Fälle, in denen ein Modell für einen bestimmten Parameter deutlich besser funktionierte als für andere. Daher wird für die weitere Untersuchung ein vereinfachter Ansatz gewählt: Ab jetzt wird jeweils ein kompletter Freiheitsgrad mit einem Regressor trainiert. Dieser Ansatz bietet den Vorteil der Einfachheit und Effizienz, ohne dabei voraussichtlich wesentliche Leistungseinbußen in Kauf nehmen zu müssen.

3.2.3 Detaillierter Modellvergleich

Die Suche nach optimalen Hyperparametern ist ein wichtiger Schritt zur Verbesserung der Modelle. Für diesen Zweck soll die Funktion `GridSearchCV` verwendet werden. Diese Methode bietet einen strukturierten Ansatz zur Hyperparameter-Optimierung. `GridSearchCV` funktioniert wie folgt:

1. Es wird eine Liste von Parametern mit verschiedenen Werten definiert
2. Die Funktion generiert alle möglichen Kombinationen dieser Parameterwerte
3. Für jede Kombination wird das Modell mit dem vorhandenen Datensatz trainiert
4. Jedes trainierte Modell wird anhand vorgegebener Kriterien bewertet
5. Am Ende werden die Parameter des besten Modells ausgegeben

Dieser Ansatz hat den Vorteil, dass er sehr gründlich ist und stellt sicher, dass die beste Kombination innerhalb des definierten Suchraums gefunden wird. Allerdings hängt bei der Vorgehensweise alles an einem guten Suchraum. Außerdem kann es auch immer eine bessere Lösung außerhalb des definierten Suchraums geben. Es gibt auch einen entscheidenden Nachteil der Methode: Mit steigender Anzahl von Parametern und Werten wächst die Zahl der zu testenden Kombinationen exponentiell. Dies kann zu sehr langen Berechnungszeiten führen, insbesondere bei komplexen Modellen oder großen Datensätzen.

Dieser Prozess wurde für jeden Freiheitsgrad separat durchgeführt. Das heißt, jeder Freiheitsgrad hat ein eigenes Modell mit dafür optimierten Hyperparametern. Die Leistungen vor und nach den Optimierungen mit `GridSearchCV` sind in Tabelle 9 dargestellt. Die Ergebnisse sind dabei der durchschnittliche Wert aus den sechs einzelnen Freiheitsgraden.

	Standard Hyperparameter			Optimierte Hyperparameter		
	MAE	MSE	R2	MAE	MSE	R2
GradientBoostingRegressor	0,164	0,071	0,524	0,167	0,072	0,524
RandomForestRegressor	0,159	0,066	0,559	0,160	0,067	0,555
ExtraTreesRegressor	0,157	0,065	0,559	0,156	0,062	0,577
MLPRegressor	0,231	0,114	-15,437	0,306	0,243	-10,981
LinearRegression	0,201	0,103	0,347	0,206	0,107	0,295

Tabelle 9: Vergleich von Metriken mit standardmäßigen und optimierten Hyperparametern

4 Ergebnisse

4.1 Vorverarbeitung

Ein wesentliches Problem bei der Vorverarbeitung der Daten war die Aufbereitung der Messreihen. Der Drift in den Daten vom Beschleunigungssensor erschwerte eine effektive Weiterverarbeitung. Die ein- oder mehrfach integrierten Daten wichen erheblich von dem erwarteten Verhalten ab. Für eine statistische Wellenanalyse ist es notwendig, Wellen in der Zeitreihe identifizieren zu können. Bei den zweifach integrierten Daten war dies jedoch oft nicht möglich, da teilweise nur ein großer Bogen in den Daten erkennbar war, anstatt einzelner Wellenmuster.

Eine Lösung für das Problem des Drifts in den Beschleunigungsdaten erwies sich als schwierig. Eine gründliche Bearbeitung hätte viel Zeit und zusätzliches Fachwissen erfordert, beispielsweise für den Vergleich mit einem oder mehreren ähnlichen Sensoren. Als Lösungsansatz wurde zunächst die Filterung verschiedener Frequenzen im Frequenzbereich mittels Hoch- und Tiefpassfilter gewählt. Diese Methode reduzierte in einigen Fällen das Übersteuern deutlich. Allerdings stellte sich heraus, dass die gewählten Grenzfrequenzen nicht universell auf alle Datenreihen anwendbar waren und für jede Reihe neu bestimmt werden mussten. Da dieser Ansatz nicht vollständig zufriedenstellend war, wurde die Strategie geändert. Statt einer zweifachen Integration wurde nun nur noch einmal integriert und mit den resultierenden Daten weitergearbeitet. Ein Vorteil dieses Vorgehens ist, dass hier überall dieselben Grenzfrequenzen verwendet werden können.

4.2 Modelltraining

Die Optimierung der Modelle, hat keine signifikante Verbesserung gezeigt. Diese Entwicklung könnte auf die Evaluierungsfunktion der GridSearchCV zurückzuführen sein, welche möglicherweise der falschen Metrik ausgerichtet war. Dadurch könnten sich die Werte nicht wie erhofft verbessert haben. Auf der anderen Seite ist es möglich, dass die vorgegebenen Parameterbereiche nicht den Bereich abgedeckt haben, welcher zu einer verbesserten Modellleistung beigetragen hätten. Um dieses Problem zu beheben, sind noch mehr Durchläufe mit der Suchfunktion notwendig, welche dann natürlich auch einen höheren Zeitaufwand bedeuten.

Das neuronale Netz (MLPRegressor) hat enttäuschende Ergebnisse geliefert. Obwohl akzeptable Werte für MAE und MSE erreicht wurden, ist der R^2 -Wert so niedrig, dass dieses Modell als ungeeignet für den vorliegenden Anwendungsfall bewertet wurde. Bei den Modellen, die auf Entscheidungsbäumen basieren (GradientBoostingRegressor, RandomForestRegressor und ExtraTreesRegressor), wurde eine starke Ähnlichkeit in den Metriken festgestellt. Diese Modelle haben konsistent die beste Performance innerhalb jedes Parameters gezeigt. Der LinearRegressor hat keine Verbesserung erfahren, welche

auch auf Probleme mit der Suche nach optimalen Hyperparametern zurückzuführen ist. Allerdings kann dieses Modell auch ohne optimierten Parametern nicht mit den leistungstärkeren baumbasierten Modellen mithalten. Dies suggeriert, dass die zugrundeliegenden Zusammenhänge in den Daten nicht linear sind und besser durch komplexere Modelle erfasst werden können.

Bei der Betrachtung der Daten zu Sway wurde deutlich, dass das Training weniger erfolgreich war als bei den zuvor analysierten Fällen. Die R^2 -Metrik fiel durchweg niedriger aus als bei allen anderen untersuchten Freiheitsgraden. Dies ist ein deutlicher Indikator dafür, dass die Modelle Schwierigkeiten hatten, die Varianz in den Daten dieses Freiheitsgrades zu erklären.

Basierend auf den Ergebnissen der Evaluation und den spezifischen Anforderungen des Anwendungsfalls wurde entschieden, das Modell RandomForestRegressor für die Generierung der Bewegungsdaten zu verwenden. Dieses Modell zeigte insgesamt die besten Ergebnisse in Bezug auf Genauigkeit und Konsistenz.

5 Zusammenfassung und Ausblick

5.1 Zusammenfassung

Die angefertigte Arbeit versucht, mittels maschinellern Lernen einen Zusammenhang zwischen Schiffsbewegungen und den Bewegungen eines Schiffs herzustellen. Die Motivation für diese Arbeit liegt in einem neuen Ansatz, Drohnen bei der Wartung der Windkraftanlagen in der Nordsee zu verwenden. Der erste Schritt der Arbeit war die Vorverarbeitung der vorhandenen Messdaten, die bei Arbeiten in der Nordsee erfasst wurden. Ein wesentliches Problem bei der Vorverarbeitung war der Drift in den Daten der Beschleunigungssensoren, was eine reibungslose Weiterverarbeitung erschwerte. Mit unterschiedlichen Methoden wurde die Datenqualität verbessert.

Die Arbeit evaluierte verschiedene Machine-Learning-Algorithmen, darunter lineare Regression, neuronale Netze und baumbasierte Modelle. Diese Modelle wurden nach einer Vorauswahl optimiert, um die besten Hyperparameter zu finden. Die baumbasierten Modelle zeigten die beste Leistung hinsichtlich Genauigkeit und Konsistenz. Die Ergebnisse zeigten, dass der RandomForestRegressor die beste Leistung erzielte und daher für die Generierung von Bewegungsdaten ausgewählt wurde.

5.2 Ausblick

Bei einem weiterführenden Projekt können mehrere Erkenntnisse aus dieser Arbeit genutzt werden. Die entwickelte Pipeline mit verschiedenen Stufen der Datenverarbeitung hat sich als sehr praktisch für das Einlesen und die Zusammenführung der Daten erwiesen. Zudem erwies sich die Programmierumgebung mit Python und Python-Notebooks als nützlich für das Ausprobieren und schnelle Erzielen von Ergebnissen.

Für zukünftige ähnliche Projekte lohnt es sich, einige komplexe Punkte und aufgetretene Lücken zu berücksichtigen: In der Datenverarbeitung ist eine verbesserte Aufbereitung der Messdaten sinnvoll. Insbesondere sollte das Problem des Drifts bei Beschleunigungssensoren behoben werden, um eine zuverlässige Konvertierung in die richtige Einheit zu gewährleisten. Dafür können verschiedene fortgeschrittene Ansätze zu mehreren Sensoren oder entsprechenden intelligenten Filtern genutzt werden. Außerdem kann eine Erhöhung der Datenmenge die Modellleistung verbessern. Bisher stehen mit 387 Einträgen relativ wenige Daten zur Verfügung. Zudem stammen die vorhandenen Messpunkte wahrscheinlich überwiegend aus gemäßigten bis ruhigen Seebedingungen, wodurch starke Meeresbewegungen im Datensatz unterrepräsentiert sind. Diese Erweiterung des Datensatzes könnte folgende Auswirkungen auf das Modelltraining haben:

- Eine Verbesserung der Modellleistung, da beispielsweise auch stärkere Bewegungen im Datensatz enthalten wären.
- Andere Modelle könnten schrittweise besser abschneiden als die bisherigen Modelle.
- Mehr Daten könnten Modelle wie neuronale Netze, die öfter große Datenmengen benötigen, leistungsfähig machen.

Mit den Bewegungsdaten, die dieses Modell nun liefern kann, kann man abschätzen, wie stark die Bewegungen des Schiffes sein werden. Anschließend kann in einem weiteren Schritt eine Zeitreihe aus den erhaltenen Parametern erstellt werden. Dafür kann ein Modell wie das vom “Pierson-Moskowitz Spektrum” oder “JONSWAP Spektrum” verwendet werden. Diese werden in [Ste12] genauer beschrieben.

Literaturverzeichnis

- [BC04] Leo Breiman und Adele Cutler. *Random Forests*. Version 5.1. 2004. URL: https://www.stat.berkeley.edu/~breiman/RandomForests/cc_home.htm.
- [Ber+17] Jadran Berbić u. a. „Application of neural networks and support vector machine for significant wave height prediction“. In: *Oceanologia* 59.3 (2017), S. 331–349. ISSN: 0078-3234. DOI: <https://doi.org/10.1016/j.oceano.2017.03.007>. URL: <https://www.sciencedirect.com/science/article/pii/S0078323417300271>.
- [Cal+20] Aurélien Callens u. a. „Using Random forest and Gradient boosting trees to improve wave forecast at a specific location“. In: *Applied Ocean Research* 104 (2020), S. 102339. ISSN: 0141-1187. DOI: <https://doi.org/10.1016/j.apor.2020.102339>. URL: <https://www.sciencedirect.com/science/article/pii/S0141118720302376>.
- [Cuba] CubePilot. *CubePilot — Autopilot-on-Module — Blue Manufactured in USA — Blue Assembled in USA — Pixhawk Original Team*. CubePilot. URL: <https://cubepilot.org/#/cube/specs> (besucht am 05.06.2024).
- [Cubb] CubePilot. *CubePilot — Autopilot-on-Module — Blue Manufactured in USA — Blue Assembled in USA — Pixhawk Original Team*. CubePilot. URL: <https://cubepilot.org/#/here/here3/specs> (besucht am 05.06.2024).
- [CWJ21] Davide Chicco, Matthijs J. Warrens und Giuseppe Jurman. „The coefficient of determination R-squared is more informative than SMAPE, MAE, MAPE, MSE and RMSE in regression analysis evaluation“. In: *PeerJ Computer Science* 7 (Juli 2021), e623. ISSN: 2376-5992. DOI: [10.7717/peerj-cs.623](https://doi.org/10.7717/peerj-cs.623). URL: <https://doi.org/10.7717/peerj-cs.623>.
- [dev23] Scikit learn developers. *Extremely Randomized Trees*. Accessed: 2024-07-18. 2023. URL: <https://scikit-learn.org/stable/modules/ensemble.html#extremely-randomized-trees>.
- [KG24] WINDEA Offshore GmbH Co. KG. *Windea FOUR Offshore Wind Farm Image*. Accessed: 2024-07-24. 2024. URL: https://www.windea-care.de/files/content/03-leistungen/windea/windea_four.jpg.
- [RN12] Stuart Russell und Peter Norvig. *Künstliche Intelligenz Ein moderner Ansatz*. Pearson Deutschland, 2012, S. 1312. ISBN: 9783868940985. URL: <https://elibrary.pearson.de/book/99.150005/9783863265045>.
- [Sci24] Scikit-learn developers. *Regression Metrics*. Accessed: 2024-07-18. 2024. URL: https://scikit-learn.org/stable/modules/model_evaluation.html#regression-metrics.
- [Sita] Copernicus Marine In Situ. *About us - Copernicus Marine In Situ TAC*. Copernicus Marine In Situ. URL: <https://marineinsitu.eu/about-us> (besucht am 05.06.2024).
- [Sitb] Copernicus Marine In Situ. *Dashboard - Copernicus Marine In Situ TAC*. Copernicus Marine In Situ. URL: <https://marineinsitu.eu/dashboard/> (besucht am 05.06.2024).
- [Ste12] Robert Stewart. *Ocean-Wave Spectra*. Accessed: 2024-07-24. 2012. URL: https://wikiwaves.org/Ocean-Wave_Spectra.
- [TAC20] *Copernicus In Situ TAC, Real Time Quality Control for WAVES*. Report. 2020. DOI: [10.13155/46607](https://doi.org/10.13155/46607). URL: <https://doi.org/10.13155/46607>.
- [Tea] ArduPilot Dev Team. *Onboard Message Log Messages*. Ardupilot. URL: <https://ardupilot.org/copter/docs/logmessages.html> (besucht am 10.06.2024).
- [Win18] Roy de Winter. „A Performance Comparison of Approaches to Combine Multiple Software Product Lines“. Magisterarb. Leiden Institute of Advanced Computer Science (LIACS), 2018. URL: <https://theses.liacs.nl/pdf/2017-2018-WinterRoyde.pdf>.

- [Wor18] World Meteorological Organization. *Guide to Wave Analysis and Forecasting*. 2. Aufl. WMO 702. WMO-No. 702. Geneva: World Meteorological Organization, 2018. URL: <https://library.wmo.int/records/item/31871-guide-to-wave-analysis-and-forecasting> (besucht am 25.06.2024).

Abbildungsverzeichnis

2	Unterteilung nach zero-upcrossing-Methode. Generiert aus eigenen Daten mithilfe der oceanlyz-Bibliothek	5
3	Beispiel für Entscheidungsbaum, der ermittelt, ob man auf einen freien Tisch warten soll; aus [RN12]	7
4	Freiheitsgrade eines Schiffs auf Englisch, aus [Win18]	9
5	Schiff Windea Four [KG24] mit eingezeichneter Position der Messbox	10
6	Schaubild Datenverarbeitung	13
7	Frequenzspektrum der Zeitreihe des Freiheitsgrades Heave in zwei Darstellungen . . .	15
8	Doppelte Integration einer Zeitreihe des Freiheitsgrades Heave	15
9	Frequenzspektrum der Zeitreihe des Freiheitsgrades Heave nach der Anwendung der Filters in zwei Darstellungen	16
10	Anwendung der Filter auf die Zeitreihe Heave (Grenzfrequenz Hochpass: 0.18Hz; Grenzfrequenz Tiefpass: 2Hz)	16
11	Anwendung der Filter auf die Zeitreihe Surge (Grenzfrequenz Hochpass: 0.18Hz; Grenzfrequenz Tiefpass: 2Hz)	16
12	Test-Training auf ganzen Freiheitsgrad	19
13	Test-Training auf einzelne Parameter der Heave-Bewegung	19
14	Test-Training auf einzelne Parameter der Sway-Bewegung	19

Tabellenverzeichnis

1	Parameter der Zeitdomäne	5
2	Parameter der Frequenzdomäne	6
3	Beschreibung des Inhalts der Hardware	9
4	Ausgewählte Messreihen mit selbst berechneten Kennwerten	11
5	Detaillierte Analyse relevanter Messreihen, aus [Tea]	11
6	Inhalt der Messdaten vom InSitu-Portal	12
7	Qualitätsparameter der BSH-Daten, nach [TAC20]	14
8	Beispiel-Ausgabe der pycaret-Bibliothek zur Analyse der Parameter der Yaw-Bewegung	20
9	Vergleich von Metriken mit standardmäßigen und optimierten Hyperparametern . . .	23